

Master 2 : ECAP

**Économétrie financière avancée**

---

# **Prévision de la volatilité sur 2023 pour l'indice ENGI**

---

Auteurs :  
ONNO Lilou  
CHOSSE Clara

Sous la direction de Monsieur DARNE

---

Février 2025

# Sommaire

<b>Introduction</b>	<b>3</b>
<b>I Analyse exploratoire</b>	<b>4</b>
<b>II Estimation des modèles de volatilités sur 2018-2022</b>	<b>13</b>
<b>III Prévvision de la volatilité sur 2023</b>	<b>18</b>
<b>Conclusion</b>	<b>21</b>

## RÉSUMÉ

Cette étude porte sur la modélisation et la prévision de la volatilité de l'action Engie entre 2018 et 2023. L'analyse exploratoire a révélé une volatilité modérée mais plus élevée que celle du CAC 40, avec des caractéristiques classiques des rendements financiers, telles que l'asymétrie négative et les queues épaisses. Lors de l'analyse économétrique, plusieurs modèles GARCH sous distributions normale et de Student ont été évalués pour capturer la dynamique de volatilité. Le modèle GJR-GARCH avec distribution de Student a montré le meilleur ajustement sur la période 2018-2022, mettant en évidence un effet de levier où les chocs négatifs influencent davantage la volatilité. Pour les prévisions de 2023, bien que le modèle RiskMetrics avec loi normale ait montré le MSE le plus faible, le modèle GJR-GARCH sous loi de Student a légèrement surperformé selon le critère  $R^2\text{OOS}$ , sans différence statistiquement significative entre les modèles, selon les tests de Diebold-Mariano.

## ABSTRACT

This study focuses on modeling and forecasting the volatility of Engie's stock between 2018 and 2023. The exploratory analysis revealed moderate volatility but higher than that of the CAC 40, with typical characteristics of financial returns, such as negative skewness and heavy tails. In the econometric analysis, several GARCH models under normal and Student's t-distributions were evaluated to capture the volatility dynamics. The GJR-GARCH model with a Student's t-distribution provided the best fit for the period 2018-2022, highlighting a leverage effect where negative shocks have a greater impact on future volatility. For the 2023 forecast, although the RiskMetrics model with a normal distribution showed the lowest MSE, the GJR-GARCH model with a Student's t-distribution slightly outperformed it according to the  $R^2\text{OOS}$  criterion, with no statistically significant difference between the models, as confirmed by Diebold-Mariano tests.

# Introduction

La volatilité des marchés financiers constitue un élément fondamental dans l'analyse et la gestion des risques pour les investisseurs, les institutions financières et les régulateurs. Dans un contexte économique marqué par des instabilités croissantes, la capacité à modéliser et prévoir efficacement cette volatilité représente un enjeu majeur pour les acteurs du marché. Cette étude se concentre sur l'étude et la prévision de la volatilité de l'action Engie (ENGI), une entreprise stratégique dans le secteur énergétique européen.

La période d'étude (2018-2023) a été particulièrement riche en événements macroéconomiques ayant affecté les marchés financiers : crises sanitaires, tensions géopolitiques et transitions énergétiques ont constitué autant de facteurs de perturbation potentiels pour les cours boursiers <sup>[1]</sup>. L'action Engie, de par son positionnement dans un secteur sensible aux mutations économiques et environnementales, offre un terrain d'étude privilégié pour l'application des méthodes économétriques avancées de modélisation de la volatilité.

Notre étude s'articule autour de trois axes principaux. Tout d'abord, nous procéderons à une analyse exploratoire des données pour identifier les caractéristiques statistiques des rendements de l'action. Ensuite, nous estimerons différents modèles de la famille GARCH sur la période 2018-2022 selon deux lois de distributions : normale et student. Enfin, nous évaluerons la performance prédictive de ces modèles sur l'année 2023 à l'aide de mesures de précision connues (MSE,  $R^2_{OOS}$ ) et de tests statistiques de comparaison (test de Diebold-Mariano).

# Chapitre I

## Analyse exploratoire

### I.1 Présentation de l'actif

Engie est un acteur majeur dans le secteur mondial de l'énergie et des services publics, figurant parmi les principaux fournisseurs d'électricité et de gaz <sup>[2]</sup>. Présent dans 70 pays à travers le monde, le groupe est le premier producteur indépendant d'électricité au niveau mondial et se distingue par ses trois grandes activités : la production d'énergie, les services à l'énergie, et la distribution de gaz. Un des engagements principaux d'Engie est de réduire son empreinte environnementale, en produisant une part importante de son électricité à partir de sources renouvelables et en mettant en œuvre une transition énergétique ambitieuse, et vise une neutralité carbone d'ici 2045<sup>[3]</sup>. Les actions d'Engie sont cotées sur Euronext Paris et font partie de l'indice boursier du CAC 40. En 2023, Engie a réalisé un chiffre d'affaires de 82,6 milliards d'euros, poursuivant ainsi sa croissance malgré les défis liés aux fluctuations du marché de l'énergie et aux exigences environnementales croissantes<sup>[4]</sup>.

Figure I.1 – Évolution du cours de l'actif ENGI : prix d'ouverture, plus hauts, plus bas et prix de clôture



La figure 1 présente l'évolution du cours de l'actif ENGI au fil du temps, en superposant les prix d'ouverture, les plus hauts, les plus bas et les prix de clôture. Bien que ces courbes suivent une dynamique similaire, certaines différences subsistent, ce qui justifie le choix d'un modèle spécifique mieux adapté à la structure des données.

Nous observons une grosse baisse du cours de l'action en 2020, en raison de la pandémie de Covid-19 et le premier confinement instauré en mars 2020. Nous notons ensuite une reprise progressive avant une nouvelle baisse, plus modérée, après janvier 2022, on peut supposer que cela est lié à la guerre en Ukraine. Le comportement de l'action d'Engie présente des caractéristiques spécifiques, telles qu'une volatilité accrue pendant les périodes de crise, ce qui justifie l'adoption de modèles financiers adaptés à ces fluctuations, nous verrons cela dans la suite de l'étude. Cependant, bien que l'évolution du prix de l'action montre des similitudes dans ses baisses, la diversité des causes sous-jacentes (pandémie et conflit géopolitique) nécessite une approche analytique prenant en compte les instabilités économiques mondiales.

## I.2 Détection des outliers

Nous allons détecter les points atypique. Ils représentent des évènements ayant significativement influencé l'évolution du cours de l'actif.

Figure I.2 – Rentabilités brutes et corrigées



Trois outliers majeurs sont observés, notamment les 9 et 12 mars 2020, périodes marquées par une forte baisse du cours de l'action. Cette chute significative semble corrélée à la crise du COVID-19, déclenchée par l'annonce du premier confinement et les incertitudes économiques qui en ont découlé. Après une reprise progressive, une nouvelle baisse, bien que plus modérée, a été observée le 1er mars 2022. En effet, les actions d'Engie ont été affectées par les répercussions de la guerre en Ukraine, qui a perturbé le secteur énergétique et entraîné une pression sur les prévisions économiques des grandes entreprises du secteur, dont Engie. Afin de limiter l'impact de ces valeurs extrêmes sur la modélisation, nous avons procédé à une correction des observations atypiques.

### I.3 Graphiques

Les Figures 3 et 4 présentent respectivement les rentabilités journalières et les rentabilités au carré avant et après correction des valeurs extrêmes. L'élévation des rentabilités au carré constitue un indicateur indirect de la volatilité des rendements de l'action, permettant ainsi d'en observer l'évolution dans le temps.

Figure I.3 – Série brute







Figure I.4 – Série corrigée



L'analyse graphique met en évidence des périodes de forte et de faible volatilité. Sur la Figure 3, le premier graphique illustre les rentabilités journalières brutes, où l'on observe plusieurs pics marqués, notamment en mars 2020 et mars 2022, traduisant des chocs importants sur le marché. Le second graphique représente les rentabilités au carré et permet de mieux appréhender la dynamique de la volatilité. Il apparaît que les périodes de crise sont associées à une variabilité accrue des rendements, reflétant une incertitude plus élevée sur les marchés financiers.

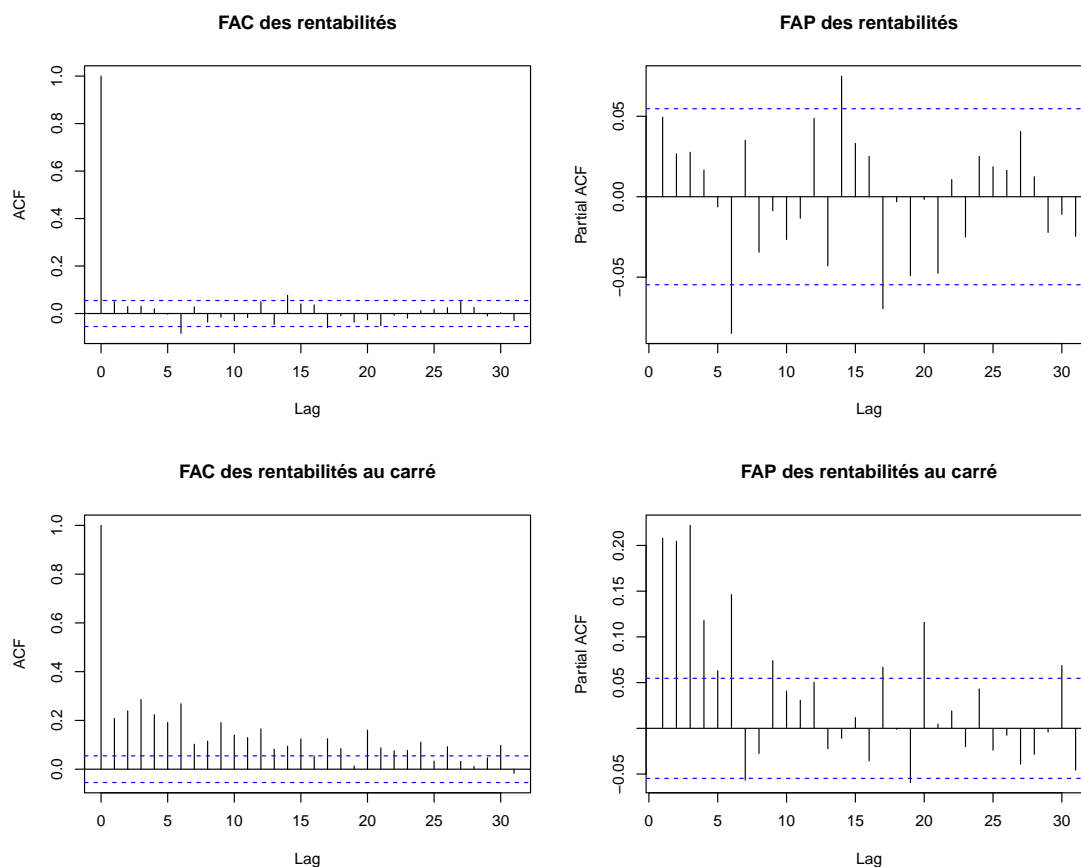
Dans la Figure 4, les rentabilités corrigées des valeurs extrêmes sont affichées. Cette correction atténue l'impact des chocs extrêmes tout en préservant la structure de volatilité sous-jacente. Bien que certaines périodes restent marquées par une volatilité importante, l'élimination des valeurs aberrantes permet une analyse plus robuste des dynamiques de marché en évitant l'influence excessive de fluctuations extrêmes.

Cette visualisation souligne ainsi la nécessité de prendre en compte la volatilité dans la modélisation des rentabilités boursières et justifie l'usage de méthodologies adaptées pour en capter les évolutions.

## I.4 Corrélogrammes

Une particularité des séries financières est que les carrés des rendements  $r_t^2$  présentent une autocorrélation significative, tandis que les rendements  $r_t$  eux-mêmes en ont peu ou pas. Cette observation justifie l'analyse des fonctions d'autocorrélation et d'autocorrélation partielle des rendements et de leurs carrés.

Figure I.5 – FAC et FACP des rentabilités



L'analyse des corrélations des rentabilités met en évidence une absence de structure apparente au niveau des rentabilités brutes. Nous notons sur la FAC un pic significatif au début et plus rien ensuite. Toutefois, lorsqu'on élève les rentabilités au carré, nous observons une structure, révélant la présence de corrélations significatives. Cette structure persistante dans les rentabilités au carré justifie un approfondissement de l'analyse et une modélisation adaptée pour en comprendre les mécanismes sous-jacents.

## I.5 Statistiques descriptives

Nous allons à présent examiner les statistiques descriptives de l'actif ENGI.

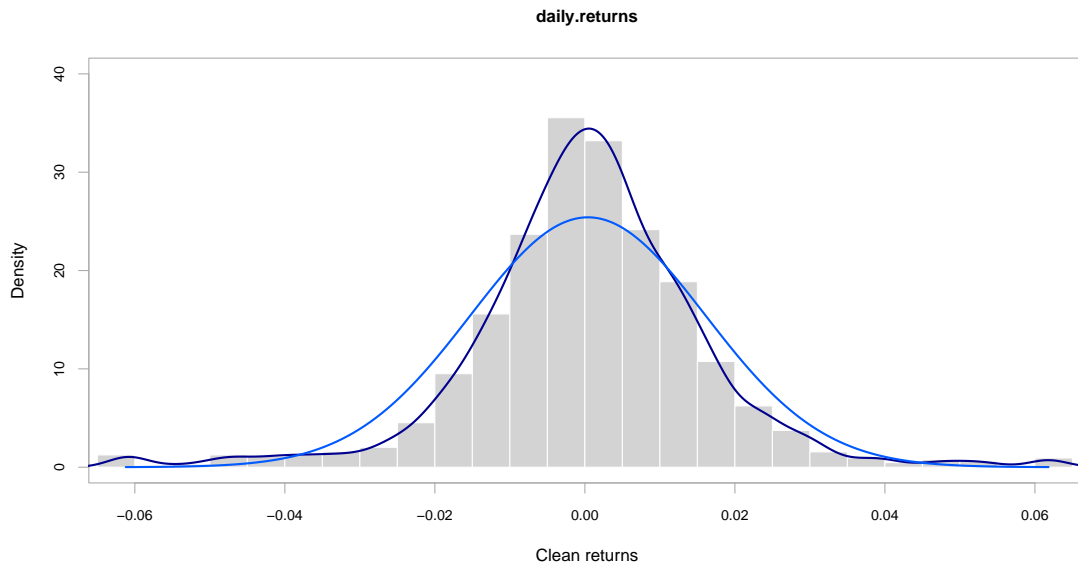
Table I.1 – Statistiques descriptives

	Moyenne (%)	Médiane (%)	Min (%)	Max (%)	Écart-type (%)	Skewness	v1	Kurtosis	v2
Série corrigée	0.0406	0.0668	-6.1212	6.1814	1.5699	-0.2033	-2.972847	2.9591	19.55686

Entre le 2 janvier 2018 et le 29 décembre 2023, l'actif ENGIE a enregistré un rendement moyen positif de 0.0406%, suggérant une création de valeur stable sur la période analysée. L'écart-type de 1.5699% reflète une volatilité modérée, liée probablement aux fluctuations des prix de l'énergie et aux enjeux de la transition énergétique. L'amplitude des rendements (12,30 points de pourcentage) confirme la présence de fluctuations importantes et la sensibilité d'Engie aux chocs externes. La valeur minimale (-6.1212%) représente une perte significative, indiquant des périodes de forte baisse tandis que la valeur maximale (6.1814%) montre un gain important, suggérant également des périodes de forte hausse. Un skewness de -3 souligne une forte asymétrie négative, suggérant une probabilité accrue d'observer des rendements fortement négatifs. Enfin, un kurtosis de 19,5 révèle une distribution leptokurtique, caractérisée par des queues épaisses et une fréquence élevée d'événements extrêmes par rapport à une distribution normale.

Afin de mieux comprendre le positionnement d'ENGIE sur le marché, nous comparons ses statistiques descriptives avec celles du CAC 40, un indice de référence représentatif du marché boursier français. Les résultats révèlent une volatilité significativement plus élevée que celle du CAC 40 (d'environ 25,7%) sur la période analysée. Ceci est surprenant pour une entreprise du secteur public, généralement considéré comme défensif, où l'on attend généralement une volatilité plus faible. En parallèle, Engie a généré un rendement moyen presque deux fois supérieur à celui du CAC 40 (0,0279%), ce qui pourrait justifier en partie sa volatilité accrue. En effet, un rendement plus élevé est souvent associé à un risque plus important, ce qui suggère qu'ENGIE présente un profil de risque-rendement plus dynamique par rapport à l'indice de référence, malgré son appartenance à un secteur généralement considéré comme plus stable. En somme, la performance d'ENGIE semble à la fois plus risquée et plus rentable que celle du marché global représenté par le CAC 40.

Figure I.6 – Représentation en histogramme de notre série



Notre analyse vient confirmer les statistiques descriptives précédemment évoquées. En effet, l'histogramme, superposé à une loi normale, met en évidence des queues épaisses aussi bien pour les gains extrêmes que pour les pertes extrêmes. Cependant, seul un test statistique permet de déterminer formellement la symétrie de la distribution.

Comme mentionné précédemment, le skewness négatif traduit une asymétrie marquée à gauche. Cela signifie que les pertes sont plus fréquentes et plus importantes que les gains, indiquant une prédominance des mouvements baissiers par rapport aux hausses..

## I.6 Caractéristiques de distribution

L'analyse des rentabilités de l'action ENGI.PA repose sur plusieurs tests statistiques visant à examiner leurs distributions. Il est essentiel de vérifier ces caractéristiques afin de déterminer les modèles économétriques adaptées.

Table I.2 – Résultat des tests sur les rentabilités de ENGI.PA

Test	p-value	Conclusion
Jarque-Bera	< 2.2e-16	Distribution non normale
Ljung-Box : rentabilités	0.04151	Auto-corrélation
Ljung-Box : rentabilités carrées	< 2.2e-16	Auto-corrélation
LM-Arch : 5 retards	< 2.2e-16	Hétéroscédasticité conditionnelle
LM-Arch : 10 retards	< 2.2e-16	Hétéroscédasticité conditionnelle

Tout d'abord, nous avons appliqué le test de Jarque Bera afin d'évaluer la normalité de la distribution des rentabilités. Les résultats indiquent une p-value inférieure à 0.05, ce qui nous permet de rejeter l'hypothèse nulle de normalité et de conclure que la distribution des rentabilités est non normale. Ensuite, afin d'analyser la dépendance temporelle des rentabilités, nous avons effectué les tests de Ljung-Box sur les rentabilités brutes et au carré. Les p-values obtenues, toutes inférieures à 0.05, révèlent une auto-corrélation significative. Cette corrélation est particulièrement marquée sur les rentabilités au carré, suggérant une dépendance dans la volatilité. Enfin, nous avons appliqué le test LM-ARCH avec 5 et 10 retards afin de vérifier l'hétéroscédasticité conditionnelle des résidus. Les résultats indiquent des p-values inférieures à 0.05, à la fois avec 5 et 10 retards, confirmant ainsi la présence d'hétéroscédasticité conditionnelle dans la série des rentabilités de l'ENGIE.PA, caractérisée par une variance non constante dans le temps. Cette caractéristique, propre aux séries financières, indique que les chocs passés influencent la volatilité future, rendant ainsi les modèles à variance constante inadaptés.

Ces résultats invalident l'hypothèse d'homoscédasticité requise par les modèles classiques tels que les MCO, rendant leur utilisation inadaptée pour la modélisation des rentabilités. Ainsi, pour capturer la dynamique de la volatilité conditionnelle confirmé par le test LM-ARCH, nous nous orientons vers des modèles d'économétrie financière, principalement des modèles GARCH, qui reposent précisément sur l'hypothèse de variance conditionnelle non constante et permettent une meilleure modélisation des fluctuations de rentabilité.

# Chapitre II

## Estimation des modèles de volatilités sur 2018-2022

Dans cette section, nous estimons des modèles de volatilité sur la période 2018-2022, en utilisant les rentabilités ajustées des données corrigées de l'actif ENGI. Nous explorons quatre modèles en considérant deux lois de distribution : la loi normale et la loi de Student.

Les modèles testés sont les suivants :

- Le modèle GARCH, qui modélise la volatilité conditionnelle en tenant compte des effets de la volatilité passée sur la volatilité future. Pour être valide, plusieurs conditions doivent être respectées, notamment la non-négativité des paramètres. La constante doit être strictement positive. Le paramètre  $\alpha$ , qui mesure la réaction de la volatilité aux chocs de marché à court terme, doit être compris entre 0 et 1. De même, le paramètre  $\beta$ , qui capture la persistance de la volatilité indépendamment des fluctuations du marché, doit être supérieur ou égal à 0. Enfin, la somme de  $\alpha$  et  $\beta$  doit être strictement inférieure à 1.
- Le modèle IGARCH, qui capture les phénomènes de longue mémoire, où un choc sur la variance conditionnelle se répercute sur toutes les valeurs futures. Ce modèle impose que la constante soit strictement positive, que  $\alpha$  et  $\beta$  soient supérieurs ou égaux à 0, et que leur somme soit égale à 1.
- Le modèle RiskMetrics, utilisé comme référence, qui accorde un poids plus important aux observations récentes. Pour ce modèle, les paramètres  $\alpha$  et  $\beta$  sont imposés.
- Le modèle GJR-GARCH, qui prend en compte l'asymétrie de la volatilité conditionnelle. Contrairement au modèle GARCH, il inclut une variable dichotomique et un paramètre

d'asymétrie , permettant de différencier l'impact des chocs positifs et négatifs de même amplitude sur la volatilité conditionnelle.

Cette approche nous permettra d'analyser et de comparer la performance de ces modèles dans la modélisation de la volatilité financière d'ENGI sur la période étudiée.

## II.1 Loi de la Distribution Normal

Dans cette section, nous présentons les résultats des modèles estimés en supposant une distribution normale des rentabilités. Le tableau ci-dessous compare les différents modèles.

Figure II.1 – Tableau comparatif des modèles estimés à partir d'une loi Normale

	Coefficient		t-value  > 1.64	persistence	half-life	log-likelihood	Akaike	HQ
GARCH	omega > 0	0,000016	0,79819	0,9340	10,15	3631,09	-5,6541	-5,648
	alpha ≥ 0	0,12860	1,5248					
	beta ≥ 0	0,805400	8,8853					
	alpha + beta < 1	0,93						
GJR-GARCH	omega > 0	0,000015	1,44	0,9363	10,53	3634,491	-5,6578	-5,6503
	alpha	0,077800	1,3665					
	beta ≥ 0	0,8113	17,28					
	gamma	0,0944	1,90					
	alpha + gamma ≥ 0	0,1722						
	alpha + beta + (gamma/2) < 1	0,9363						
IGARCH	omega > 0	0,000009	3,5062			3620,634	-5,6393	-5,635
	alpha ≥ 0	0,188	4,0642					
	beta	0,812						
Riskmetrics	alpha	0,06				3606,8	-5,6209	-5,6194
	beta	0,94						

Dans l'analyse des modèles GARCH et IGARCH, nous observons que certains paramètres présentent une statistique t inférieure à 1,64, ce qui indique qu'ils ne sont pas significatifs au seuil de 10%. En effet, la constante ainsi le paramètre alpha des modèle GARCH et IGARCH ne sont pas significatif au seuil de 10%, ce qui remet en cause la validité de deux de ces modèles. En revanche, les modèles IGARCH et Riskmetrics présentent des coefficients dont les t-statistics sont supérieures à 1,64, ce qui signifie qu'ils sont statistiquement significatifs au seuil de 10%, nous permettant de conserver ces modèles.

Le modèle optimal est le modèle IGARCH car il maximise le critère Log-Likelihood et minimise l'AIC. C'est le modèle le plus adapté pour modéliser la volatilité des données, car il offre le meilleur compromis entre qualité d'ajustement et parcimonie. De plus, il n'y a pas

d'asymétrie, cela indique que les chocs positifs et négatifs ont un impact similaire sur la volatilité. La persistance des chocs est finie, c'est à dire qu'ils vont disparaître avec le temps.

## II.2 Loi de la Distribution de Student

Dans cette section, nous appliquons la même analyse en supposant une distribution de Student pour les rentabilités. Le tableau ci-dessous présente les résultats des modèles estimés sous cette hypothèse.

Figure II.2 – Tableau comparatif des modèles estimés à partir d'une distribution de Student

	Coefficient		t-value  > 1.64	persistance	half-life	log-likelihood	Akaike	HQ
GARCH	Cst(V) > 0	0,000013	5,43	0,9574	15,92	3671,827	-5,716	-5,7085
	alpha ≥ 0	0,142	6,90					
	beta ≥ 0	0,8154	30,04					
	alpha + beta < 1	0,9574						
	Student	5,0687	6,33					
GJR-GARCH	Cst(V) > 0	0,000012	7,2904	0,183	0,41	3674,204	-5,7182	-5,7091
	alpha	0,0892	3,83					
	beta ≥ 0	0,8216	33,3245					
	gamma	0,0934	1,884					
	alpha + gamma ≥ 0	0,1826						
	alpha + beta + (gamma/2) < 1	0,958						
	Student	5,155	6,7428					
IGARCH	Cst(V) > 0	0,000009	4,4673			3669,818	-5,7144	-5,7084
	alpha ≥ 0	0,1707	5,6157					
	beta	0,8293						
	Student	4,3207	8,6709					
Riskmetrics	alpha	0,06				3658,4	-5,6998	-5,6967
	beta	0,94						
	Student	5,5165	9,7613					

Les constantes des modèles GARCH, GJR-GARCH, IGARCH et RiskMetrics sont toutes statistiquement significatives, avec des t-statistiques supérieures à 1,64, ce qui indique qu'elles contribuent de manière fiable à la modélisation de la volatilité dans nos données. Cependant, la constante seule ne constitue pas un critère suffisant pour la sélection finale du modèle. En effet, notre analyse se concentrera principalement sur l'évaluation des paramètres  $\alpha$  et  $\beta$ , qui mesurent respectivement la réactivité de la volatilité aux chocs de marché et la persistance de cette volatilité dans le temps. Ces deux paramètres jouent un rôle essentiel dans la précision de la modélisation des fluctuations de la rentabilité.

Ensuite, en ce qui concerne l'analyse des résultats, nous pouvons confirmer que toutes les variables incluses dans nos modèles sont également statistiquement significatives, avec



des t-statistiques supérieures à 1,64, ce qui valide leur pertinence pour capturer la dynamique de la volatilité.

Enfin, pour comparer nos modèles, nous utilisons deux critères : l'AIC (Akaike Information Criterion) et le log-vraisemblance (Log-Likelihood). Les résultats montrent que le modèle GJR-GARCH minimise l'AIC et maximise le Log-Likelihood, ce qui en fait le modèle le plus performant parmi ceux testés. Le modèle GJR-GARCH, en optimisant ces deux critères, offre ainsi le meilleur compromis entre ajustement des données et complexité, ce qui en fait le choix optimal pour modéliser la volatilité de l'actif étudié.

### **Synthèse des deux tableaux :**

Après analyse des deux tableaux utilisant respectivement la loi normale et la loi de Student, nous avons retenu les modèles IGARCH et RiskMetrics pour la loi normale, ainsi que les quatre modèles (GARCH, GJR-GARCH, IGARCH, et RiskMetrics) pour la loi de Student. Cela donne un total de six modèles à considérer pour la suite de notre étude. Cependant, deux modèles se distinguent particulièrement : IGARCH pour la loi normale et GJR-GARCH pour la loi de Student. Finalement, le modèle GJR-GARCH (loi de Student) maximise la log-vraisemblance (LL) et minimise l'AIC parmi ces deux, ce qui nous conduit à l'interpréter comme étant le plus pertinent.

Concernant les paramètres estimés, le coefficient alpha ( $\alpha = 0,0892$ ) est statistiquement significatif et reflète l'impact des innovations récentes, suggérant une sensibilité modérée de la volatilité aux chocs immédiats. Le coefficient beta illustre la persistance de la volatilité, soulignant l'influence durable des conditions passées sur la volatilité actuelle. La valeur positive du paramètre gamma confirme l'existence d'un effet de levier, où les chocs négatifs entraînent une volatilité future plus élevée que les chocs positifs de même ampleur. En effet, l'effet cumulatif des chocs négatifs ( $\alpha + \gamma = 0,1826$ ) est presque deux fois supérieur à celui des chocs positifs ( $\alpha = 0,0892$ ), validant l'hypothèse d'une asymétrie dans la dynamique de la volatilité. Enfin, le paramètre de degrés de liberté dans la distribution de Student confirme l'existence de queues plus épaisses que celles de la distribution normale, suggérant que les rendements financiers sont mieux modélisés par une distribution leptokurtique, où les événements extrêmes sont plus fréquents.

## **II.3 Diagnostic des résidus**

La section suivante présente le diagnostic des résidus des modèles IGARCH et RiskMetrics pour la loi normale, ainsi que des modèles GARCH, GJR-GARCH, IGARCH et Risk-

Metrics pour la loi de Student, en utilisant divers tests pour évaluer l'autocorrélation et l'homoscédasticité des résidus.

Table II.1 – Diagnostics des résidus

<b>Modèle</b>	<b>Loi</b>	<b>Q(5)</b>	<b>P-value</b>	<b>Q(5)<sup>2</sup></b>	<b>P-value</b>	<b>LM-ARCH(5)</b>	<b>P-value</b>
IGARCH	Normale	3.556	0.6149	1.7015	0.8887	1.7478	0.8828
Riskmetrics	Normale	3.361	0.6445	10.692	0.05784	9.5709	0.08835
GARCH	Student	3.4799	0.6264	0.74507	0.9804	0.73219	0.9812
GJR-GARCH	Student	3.4568	0.6299	0.50379	0.992	0.50938	0.9918
IGARCH	Student	3.594	0.6092	1.0449	0.9589	1.0514	0.9583
Riskmetrics	Student	3.4301	0.634	10.537	0.06138	9.4628	0.09197

Pour tous les modèles étudiés, la p-value associée au test de Ljung-Box sur les résidus est supérieure à 0,05, ce qui signifie que nous ne pouvons pas rejeter l'hypothèse nulle au seuil de 5%. Ainsi, il n'y a pas d'autocorrélations significatives dans les résidus pour aucun des modèles. De même, les tests de Ljung-Box sur les résidus standardisés au carré montrent également des p-values supérieures à 0,05 pour tous les modèles, confirmant qu'il n'y a pas d'autocorrélation significative dans les résidus standardisés au seuil de 5%. Enfin, les tests d'homoscédasticité conditionnelle sur les résidus standardisés révèlent que l'hypothèse nulle d'homoscédasticité est acceptée pour tous les modèles, suggérant que la variance des résidus reste constante au cours du temps.

# Chapitre III

## Prévision de la volatilité sur 2023

Nous allons maintenant réaliser des prévisions de la volatilité de l'actif ENGIE.PA pour l'année 2023. Pour cela, nous utiliserons deux mesures différentes et évaluerons la précision des modèles IGARCH et RiskMetrics pour une distribution normale, ainsi que les modèles GARCH, IGARCH, RiskMetrics et GJR-GARCH pour une distribution de Student. Les analyses précédentes ayant confirmé la pertinence de ces modèles, nous les retenons pour cette étude.

### III.1 Comparaison des modèles

Nous utilisons quatre mesures pour évaluer la performance des prévisions de nos modèles.

Table III.1 – Comparaison de la précision de prévision des modèles

	Normale		Student			
	IGARCH	Riskmetrics	GARCH	IGARCH	Riskmetrics	GJR
MSE ( $\times 10^4$ )	0.0001337046	0.0001289775	0.0001354723	0.0001405168	0.00012897	0.0001368201
R2OOS	-0.03664983	0	-0.03395837	-0.08946699	-0.03395837	0.00005874784
MCS_R p-value	1	1	1	1	1	1
Rank_R	3	5	6	1	4	2

Tout d'abord, la métrique MSE (Mean Squared Error) correspond à la moyenne des erreurs de prédiction au carré : plus il est faible, plus le modèle est précis. Elle permet d'évaluer la précision des prévisions en quantifiant l'écart moyen entre les valeurs prédites et les valeurs observées. Afin de faciliter l'interprétation, nous multiplierons le résultat par 100 000. Selon le critère du MSE, le modèle RiskMetrics avec loi normale se distingue comme le meilleur modèle

parmi ceux listés dans le tableau, avec un MSE de 0.0001289775, le plus bas parmi tous les modèles testés. En revanche, IGARCH avec une loi de student(0.0001405168) présente l'erreur la plus élevée.

Ensuite, nous utilisons le  $R^2OOS$ , qui compare la qualité des prévisions de nos modèles par rapport à un modèle de référence. Dans cette étude, le modèle RiskMetrics avec une loi normale est choisi comme modèle de référence, ce qui lui attribue un  $R^2OOS$  de 0. Une valeur positive de  $R^2OOS$  indique que le modèle testé surperforme ce modèle de référence. Ici, seul le modèle GJR-GARCH avec une loi de Student (qui obtient un score positif) surperforme légèrement RiskMetrics avec une loi normale dans ce cas particulier.

La troisième mesure, MSC R p-value, permet d'évaluer la significativité statistique des différences de performance entre les modèles. Une p-value faible indique que l'amélioration observée est significative et non due au hasard. Les résultats montrent que tous les modèles présentent une p-value de 1, indiquant qu'aucune différence statistiquement significative entre eux n'a pu être détectée.

Enfin, le Rank R est un classement des modèles basé sur l'ensemble des critères de performance. Il permet d'identifier le modèle offrant la meilleure prévision en tenant compte de plusieurs métriques simultanément. Dans nos cas, le modèle IGARCH avec une loi de student est le modèle le mieux classé (rang 1), tandis que le modèle GARCH avec une loi de student arrive dernier, avec un rang de 6.

En conclusion, RiskMetrics est le modèle le plus précis en termes de MSE, mais il ne surpasse pas toujours les autres modèles selon le critère  $R^2OOS$ . GJR-GARCH est le seul à surpasser RiskMetrics, bien que l'amélioration soit minime. En résumé, RiskMetrics demeure un modèle solide, mais GJR-GARCH pourrait être préféré en raison de son  $R^2OOS$  positif.

## III.2 Tests de comparaison de précision

Le test de Diebold et Mariano (DM) est utilisé pour comparer la performance de plusieurs modèles de prévision en fonction de la précision de leurs erreurs. Il est particulièrement utile pour évaluer si deux modèles diffèrent significativement en termes d'efficacité de prévision. Le tableau ci dessous présente les résultats de ce test pour nos différents modèles en utilisant deux distributions : Normale et Student.

L'interprétation des résultats repose sur la p-value associée à chaque comparaison. Lorsque la p-value est inférieure à 0,05, cela indique une différence statistiquement significa-

tive entre les modèles, suggérant qu'un modèle est plus performant qu'un autre. En revanche, lorsque la p-value est supérieure à 0,05, cela indique l'absence de différence significative, les performances des deux modèles étant considérées comme similaires.

Table III.2 – Résultats du test de Diebold et Mariano

		Normale		Student			
		IGARCH	Riskmetrics	GARCH	IGARCH	Riskmetrics	GJR
Loi Normal	IGARCH						
	Riskmetrics	0.2651					
Loi Student	GARCH	0.4411	0.0007				
	IGARCH	0	0	0			
	Riskmetrics	0.2413	0.9326	0.0004	0		
	GJR	0.0512	0.0033	0.4387	0	0.0024	

Les résultats montrent que le modèle IGARCH avec une loi normale présente majoritairement des p-values supérieures à 0,05, indiquant qu'il n'y a pas de différence statistiquement significative entre ses performances et celles des autres modèles, à l'exception de l'IGARCH avec une loi de Student. Ce dernier affiche une p-value de 0, suggérant que l'IGARCH avec une loi normale est plus performant que celui avec une loi de Student dans ce cas spécifique.

Concernant le modèle RiskMetrics avec une loi normale, il semble offrir de meilleures performances que le modèle GJR ( $p = 0.0033$ ), ainsi que par rapport aux modèles GARCH et IGARCH (loi normale). En revanche, aucune différence significative n'est observée entre RiskMetrics avec une loi normale et RiskMetrics avec une loi de Student ( $p = 0,9326$ ), ce qui suggère que les deux configurations offrent des performances similaires.

Dans l'ensemble, les p-values des tests sont réparties de manière relativement équilibrée entre des valeurs inférieures et supérieures à 0,05, ce qui indique que certains modèles présentent des différences marquées en termes de performance, tandis que d'autres sont similaires dans leur capacité de prévision.

# Conclusion

Cette étude a permis d'analyser en profondeur la volatilité de l'action Engie sur la période 2018-2023, révélant plusieurs caractéristiques importantes pour la compréhension de cet actif financier. L'analyse exploratoire a mis en évidence deux périodes de chocs majeurs : la crise du COVID-19 en mars 2020 et les répercussions de la guerre en Ukraine en mars 2022. Ces événements ont significativement impacté le cours de l'action, illustrant la sensibilité d'Engie aux crises mondiales malgré son positionnement dans un secteur traditionnellement défensif. La volatilité de l'actif, supérieure à celle du CAC 40, combinée à un rendement moyen presque deux fois plus élevé, témoigne d'un profil risque-rendement plus dynamique qu'attendu pour une entreprise du secteur énergétique public. Les tests statistiques ont confirmé les propriétés typiques des séries financières : distribution non normale avec asymétrie négative marquée et queues épaisses, absence d'autocorrélation dans les rendements mais présence significative dans leurs carrés, et hétéroscédasticité conditionnelle. Ces caractéristiques ont justifié l'utilisation de modèles GARCH pour capturer adéquatement la dynamique de volatilité. Parmi les modèles estimés, le GJR-GARCH avec distribution de Student s'est révélé le plus performant pour la période 2018-2022, avec des paramètres tous significatifs. L'identification d'un effet de levier substantiel confirme que les chocs négatifs impactent plus fortement la volatilité future d'Engie que les chocs positifs de même ampleur, une information précieuse pour les gestionnaires de risque. Pour les prévisions sur 2023, nos résultats montrent que plusieurs modèles offrent des performances comparables. Si RiskMetrics avec une loi normale présente l'erreur quadratique moyenne la plus faible, le modèle GJR-GARCH avec loi de Student est le seul à surperformer légèrement ce modèle de référence selon le  $R^2_{OOS}$ . Les tests de Diebold-Mariano confirment toutefois l'absence de différence statistiquement significative entre plusieurs configurations, suggérant une certaine équivalence pratique entre ces approches pour la prévision à court terme.

Pour approfondir, notre analyse pourrait être enrichi en incluant des variables exogènes liées au secteur énergétique (prix des matières premières, évolutions réglementaires) ou l'ex-

ploration de modèles plus complexes intégrant des composantes de long terme pour mieux capturer les effets persistants des chocs sur la volatilité d'Engie.

# Annexes

## Annexe 1 : Modèle GARCH avec loi normale

```
*-----*
*          GARCH Model Fit          *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : sGARCH(1,1)
Mean Model       : ARFIMA(0,0,0)
Distribution      : norm

Optimal Parameters
-----
      Estimate Std. Error  t value Pr(>|t|)
mu      0.000555   0.000370   1.4971 0.134366
omega   0.000016   0.000005   2.9478 0.003200
alpha1  0.128600   0.027293   4.7119 0.000002
beta1    0.805326   0.030650  26.2753 0.000000

Robust Standard Errors:
      Estimate Std. Error  t value Pr(>|t|)
mu      0.000555   0.000399   1.3897 0.16484
omega   0.000016   0.000019   0.84231 0.39962
alpha1  0.128600   0.080373   1.60004 0.10959
beta1    0.805326   0.086608   9.29853 0.00000

LogLikelihood : 3630.957

Information Criteria
-----
Akaike      -5.6539
Bayes       -5.6378
Shibata     -5.6539
Hannan-Quinn -5.6478
```

## Annexe 3 : Modèle IGARCH avec loi normale

```
*-----*
*          GARCH Model Fit          *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : iGARCH(1,1)
Mean Model       : ARFIMA(0,0,0)
Distribution      : norm

Optimal Parameters
-----
      Estimate Std. Error  t value Pr(>|t|)
mu      0.000524   0.000383   1.3688 0.171061
omega   0.000009   0.000002   4.8672 0.000001
alpha1  0.187801   0.028553   6.5773 0.000000
beta1    0.812199         NA         NA         NA

Robust Standard Errors:
      Estimate Std. Error  t value Pr(>|t|)
mu      0.000524   0.000414   1.2682 0.204733
omega   0.000009   0.000003   3.4901 0.000483
alpha1  0.187801   0.046326   4.0539 0.000050
beta1    0.812199         NA         NA         NA

LogLikelihood : 3620.504

Information Criteria
-----
Akaike      -5.6391
Bayes       -5.6271
Shibata     -5.6391
Hannan-Quinn -5.6346

Weighted Ljung-Box Test on Standardized Residuals
-----
```

## Annexe 2 : Modèle GJR-GARCH avec loi normale

```
*-----*
*          GARCH Model Fit          *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : gjrGARCH(1,1)
Mean Model       : ARFIMA(0,0,0)
Distribution      : norm

Optimal Parameters
-----
      Estimate Std. Error  t value Pr(>|t|)
mu      0.000404   0.000370   1.0908 0.275365
omega   0.000015   0.000004   4.0678 0.000047
alpha1  0.077980   0.005237   14.8892 0.000000
beta1    0.811155   0.013549   59.8672 0.000000
gamma1   0.094156   0.036849   2.5552 0.010614

Robust Standard Errors:
      Estimate Std. Error  t value Pr(>|t|)
mu      0.000404   0.000392   1.0283 0.303811
omega   0.000015   0.000011   1.3460 0.178310
alpha1  0.077980   0.060380   1.2915 0.196534
beta1    0.811155   0.049521  16.3801 0.000000
gamma1   0.094156   0.049844   1.8890 0.058889

LogLikelihood : 3634.351

Information Criteria
-----
Akaike      -5.6576
Bayes       -5.6375
Shibata     -5.6576
Hannan-Quinn -5.6501
```

## Annexe 4 : Modèle Riskmetrics avec loi normale

```
*-----*
*          GARCH Model Fit          *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : iGARCH(1,1)
Mean Model       : ARFIMA(0,0,0)
Distribution      : norm

Optimal Parameters
-----
      Estimate Std. Error  t value Pr(>|t|)
mu      0.000148   0.000377   0.39156 0.69538
omega   0.000000         NA         NA         NA
alpha1  0.060000         NA         NA         NA
beta1    0.940000         NA         NA         NA

Robust Standard Errors:
      Estimate Std. Error  t value Pr(>|t|)
mu      0.000148   0.000532   0.2775 0.7814
omega   0.000000         NA         NA         NA
alpha1  0.060000         NA         NA         NA
beta1    0.940000         NA         NA         NA

LogLikelihood : 3606.671

Information Criteria
-----
Akaike      -5.6207
Bayes       -5.6167
Shibata     -5.6207
Hannan-Quinn -5.6192

Weighted Ljung-Box Test on Standardized Residuals
-----
```



## Annexe 5 : Modèle GARCH avec loi de student

```

*-----*
*          GARCH Model Fit          *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : sGARCH(1,1)
Mean Model       : ARFIMA(0,0,0)
Distribution      : std

Optimal Parameters
-----
      Estimate Std. Error t value Pr(>|t|)
mu      0.000741  0.000332  2.2320 0.025617
omega    0.000013  0.000002  7.2977 0.000000
alpha1    0.141982  0.014636  9.7012 0.000000
beta1     0.815346  0.022067 36.9490 0.000000
shape     5.065507  0.559354  9.0560 0.000000

Robust Standard Errors:
      Estimate Std. Error t value Pr(>|t|)
mu      0.000741  0.000335  2.2085 0.027212
omega    0.000013  0.000002  5.4094 0.000000
alpha1    0.141982  0.020597  6.8932 0.000000
beta1     0.815346  0.027173 30.0054 0.000000
shape     5.065507  0.800395  6.3288 0.000000

LogLikelihood : 3671.724

Information Criteria
-----
Akaike      -5.7159
Bayes       -5.6958
Shibata     -5.7159
Hannan-Quinn -5.7083

```

## Annexe 6 : Modèle GJR-GARCH avec loi de student

```

*-----*
*          GARCH Model Fit          *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : gjrGARCH(1,1)
Mean Model       : ARFIMA(0,0,0)
Distribution      : std

Optimal Parameters
-----
      Estimate Std. Error t value Pr(>|t|)
mu      0.000627  0.000333  1.8819 0.059847
omega    0.000012  0.000001  8.7106 0.000000
alpha1    0.089361  0.019734  4.5283 0.000006
beta1     0.821553  0.021838 37.6197 0.000000
gamma1    0.093214  0.043379  2.1488 0.031649
shape     5.150827  0.606699  8.4899 0.000000

Robust Standard Errors:
      Estimate Std. Error t value Pr(>|t|)
mu      0.000627  0.000334  1.8782 0.060359
omega    0.000012  0.000002  7.2893 0.000000
alpha1    0.089361  0.023266  3.8409 0.000123
beta1     0.821553  0.024667 33.3064 0.000000
gamma1    0.093214  0.049585  1.8799 0.060122
shape     5.150827  0.763326  6.7479 0.000000

LogLikelihood : 3674.095

Information Criteria
-----
Akaike      -5.7180
Bayes       -5.6939
Shibata     -5.7180
Hannan-Quinn -5.7089

```

## Annexe 7 : Modèle IGARCH avec loi de student

```

*-----*
*          GARCH Model Fit          *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : iGARCH(1,1)
Mean Model       : ARFIMA(0,0,0)
Distribution      : std

Optimal Parameters
-----
      Estimate Std. Error t value Pr(>|t|)
mu      0.000762  0.000328  2.3207 0.020303
omega    0.000009  0.000003  3.6287 0.000285
alpha1    0.170679  0.029438  5.7980 0.000000
beta1     0.829321      NA      NA      NA
shape     4.318379  0.486679  8.8732 0.000000

Robust Standard Errors:
      Estimate Std. Error t value Pr(>|t|)
mu      0.000762  0.000325  2.3423 0.019166
omega    0.000009  0.000002  4.4700 0.000008
alpha1    0.170679  0.030402  5.6141 0.000000
beta1     0.829321      NA      NA      NA
shape     4.318379  0.497550  8.6793 0.000000

LogLikelihood : 3669.718

Information Criteria
-----
Akaike      -5.7143
Bayes       -5.6982
Shibata     -5.7143
Hannan-Quinn -5.7083

```

## Annexe 8 : Modèle Riskmetrics avec loi de student

```

*-----*
*          GARCH Model Fit          *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : iGARCH(1,1)
Mean Model       : ARFIMA(0,0,0)
Distribution      : std

Optimal Parameters
-----
      Estimate Std. Error t value Pr(>|t|)
mu      0.000777  0.000338  2.3004 0.021428
omega    0.000000      NA      NA      NA
alpha1    0.060000      NA      NA      NA
beta1     0.940000      NA      NA      NA
shape     5.512631  0.602296  9.1527 0.000000

Robust Standard Errors:
      Estimate Std. Error t value Pr(>|t|)
mu      0.000777  0.00037  2.1022 0.035534
omega    0.000000      NA      NA      NA
alpha1    0.060000      NA      NA      NA
beta1     0.940000      NA      NA      NA
shape     5.512631  0.56403  9.7737 0.000000

LogLikelihood : 3658.292

Information Criteria
-----
Akaike      -5.6996
Bayes       -5.6916
Shibata     -5.6996
Hannan-Quinn -5.6966

```

## Annexe 9 : Test Ljung-Box sur les résidus

```
> # Test Ljung-Box sur les résidus
> Box.test(residuals(mod_norm3, standardize = TRUE), lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_norm3, standardize = TRUE)
X-squared = 3.5486, df = 5, p-value = 0.6161

> Box.test(residuals(mod_norm4, standardize = TRUE), lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_norm4, standardize = TRUE)
X-squared = 3.3553, df = 5, p-value = 0.6454

>
>
> Box.test(residuals(mod_std1, standardize = TRUE), lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_std1, standardize = TRUE)
X-squared = 3.4734, df = 5, p-value = 0.6274

> Box.test(residuals(mod_std2, standardize = TRUE), lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_std2, standardize = TRUE)
X-squared = 3.45, df = 5, p-value = 0.631

> Box.test(residuals(mod_std3, standardize = TRUE), lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_std3, standardize = TRUE)
X-squared = 3.587, df = 5, p-value = 0.6103

> Box.test(residuals(mod_std4, standardize = TRUE), lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_std4, standardize = TRUE)
X-squared = 3.4247, df = 5, p-value = 0.6348

> |
```

## Annexe 10 : Test Ljung-Box sur les carrés des résidus

```
> # Test Ljung-Box sur les carrés des résidus
> Box.test(residuals(mod_norm3, standardize = TRUE)^2, lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_norm3, standardize = TRUE)^2
X-squared = 1.703, df = 5, p-value = 0.8885

> Box.test(residuals(mod_norm4, standardize = TRUE)^2, lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_norm4, standardize = TRUE)^2
X-squared = 10.72, df = 5, p-value = 0.05723

>
> Box.test(residuals(mod_std1, standardize = TRUE)^2, lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_std1, standardize = TRUE)^2
X-squared = 0.74486, df = 5, p-value = 0.9804

> Box.test(residuals(mod_std2, standardize = TRUE)^2, lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_std2, standardize = TRUE)^2
X-squared = 0.50489, df = 5, p-value = 0.9919

> Box.test(residuals(mod_std3, standardize = TRUE)^2, lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_std3, standardize = TRUE)^2
X-squared = 1.0416, df = 5, p-value = 0.9591

> Box.test(residuals(mod_std4, standardize = TRUE)^2, lag = 5, type = "Ljung-Box")

Box-Ljung test

data: residuals(mod_std4, standardize = TRUE)^2
X-squared = 10.557, df = 5, p-value = 0.06091
```

## Annexe 11 : Test LM-ARCH(5) sur les résidus

```
> # Test LM-ARCH(5) sur les résidus
> ArchTest(residuals(mod_norm3, standardize = TRUE), lags = 5)

ARCH LM-test; Null hypothesis: no ARCH effects

data: residuals(mod_norm3, standardize = TRUE)
Chi-squared = 1.7494, df = 5, p-value = 0.8826

> ArchTest(residuals(mod_norm4, standardize = TRUE), lags = 5)

ARCH LM-test; Null hypothesis: no ARCH effects

data: residuals(mod_norm4, standardize = TRUE)
Chi-squared = 9.5908, df = 5, p-value = 0.0877

>
> ArchTest(residuals(mod_std1, standardize = TRUE), lags = 5)

ARCH LM-test; Null hypothesis: no ARCH effects

data: residuals(mod_std1, standardize = TRUE)
Chi-squared = 0.73193, df = 5, p-value = 0.9812

> ArchTest(residuals(mod_std2, standardize = TRUE), lags = 5)

ARCH LM-test; Null hypothesis: no ARCH effects

data: residuals(mod_std2, standardize = TRUE)
Chi-squared = 0.51034, df = 5, p-value = 0.9917

> ArchTest(residuals(mod_std3, standardize = TRUE), lags = 5)

ARCH LM-test; Null hypothesis: no ARCH effects

data: residuals(mod_std3, standardize = TRUE)
Chi-squared = 1.048, df = 5, p-value = 0.9586

> ArchTest(residuals(mod_std4, standardize = TRUE), lags = 5)

ARCH LM-test; Null hypothesis: no ARCH effects

data: residuals(mod_std4, standardize = TRUE)
Chi-squared = 9.4754, df = 5, p-value = 0.09154
```

# Bibliographie

- [1] HAL, “L’impact des évènements macroéconomiques sur la liquidité des fonds d’investissement,” 2022.
- [2] C. Martin, “Choisir le fournisseur d’énergie Engie : notre guide complet,” 12 2024.
- [3] “Nos engagements pour le climat | ENGIE.”
- [4] Statista, “Chiffre d’affaires du groupe ENGIE 2011-2023,” 3 2024.

# Liste des tableaux

I.1	Statistiques descriptives . . . . .	10
I.2	Résultat des tests sur les rentabilités de ENGI.PA . . . . .	12
II.1	Diagnostics des résidus . . . . .	17
III.1	Comparaison de la précision de prévision des modèles . . . . .	18
III.2	Résultats du test de Diebold et Mariano . . . . .	20

# Table des figures

I.1	Évolution du cours de l'actif ENGI : prix d'ouverture, plus hauts, plus bas et prix de clôture . . . . .	5
I.2	Rentabilités brutes et corrigées . . . . .	6
I.3	Série brute . . . . .	7
I.4	Série corrigée . . . . .	8
I.5	FAC et FACP des rentabilités . . . . .	9
I.6	Représentation en histogramme de notre série . . . . .	11
II.1	Tableau comparatif des modèles estimés à partir d'une loi Normale . . . . .	14
II.2	Tableau comparatif des modèles estimés à partir d'une distribution de Student	15
III.1	Annexe 1 : Modèle GARCH avec loi normale . . . . .	23
III.2	Annexe 2 : Modèle GJR-GARCH avec loi normale . . . . .	23
III.3	Annexe 3 : Modèle IGARCH avec loi normale . . . . .	23
III.4	Annexe 4 : Modèle Riskmetrics avec loi normale . . . . .	23
III.5	Annexe 5 : Modèle GARCH avec loi de student . . . . .	24
III.6	Annexe 6 : Modèle GJR-GARCH avec loi de student . . . . .	24
III.7	Annexe 7 : Modèle IGARCH avec loi de student . . . . .	24
III.8	Annexe 8 : Modèle Riskmetrics avec loi de student . . . . .	24
III.9	Annexe 9 : Test Ljung-Box sur les résidus . . . . .	25
III.10	Annexe 10 : Test Ljung-Box sur les carrés des résidus . . . . .	25
III.11	Annexe 11 : Test LM-ARCH(5) sur les résidus . . . . .	25

# Table des matières

<b>Introduction</b>	<b>3</b>
<b>I Analyse exploratoire</b>	<b>4</b>
I.1 Présentation de l'actif . . . . .	4
I.2 Détection des outliers . . . . .	5
I.3 Graphiques . . . . .	6
I.4 Corrélogrammes . . . . .	9
I.5 Statistiques descriptives . . . . .	10
I.6 Caractéristiques de distribution . . . . .	11
<b>II Estimation des modèles de volatilités sur 2018-2022</b>	<b>13</b>
II.1 Loi de la Distribution Normal . . . . .	14
II.2 Loi de la Distribution de Student . . . . .	15
II.3 Diagnostic des résidus . . . . .	16
<b>III Prévision de la volatilité sur 2023</b>	<b>18</b>
III.1 Comparaison des modèles . . . . .	18
III.2 Tests de comparaison de précision . . . . .	19
<b>Conclusion</b>	<b>21</b>